NeoRetail — Architecture logique

1 · SOURCES DE DONNÉES

Fichiers livrés chaque jour / référentiels (batch)

- **Ventes magasins** — CSV
- **Commandes en ligne** — en-têtes + lignes · CSV
- **Retours** — CSV
- **Référentiels** — clients · produits · magasins
- **Changements clients** — CDC · JSONL

Temps réel

- **Navigation web** — clickstream · JSONL

▼

2 · INGESTION

- **Zone d'atterrissage** — MinIO · fichiers bruts rangés par jour
- **Airflow** — chargement quotidien · rejouable · reprise sur erreur
- **Redpanda** — file de messages (topic)
- **Spark Streaming** — lecture continue · reprise

▼

3 · LAKEHOUSE — TABLES ICEBERG SUR MINIO, CATALOGUE HIVE METASTORE

BRONZE
copie brute des sources
+ informations de traçabilité

dbt (stg_)
+ contrôles qualité →

SILVER
données typées, sans doublons
pseudonymisées (RGPD)

dbt (int_, dim_, fct_)
+ contrôles qualité →

GOLD
schéma en étoile · agrégats
couche sémantique

Requêtes SQL avec **Trino** · transformations SQL versionnées avec **dbt**

▼ seule la zone Gold est exposée

4 · CONSOMMATION

- **Superset** — tableaux de bord : CA, panier moyen, conversion, retours
- **MLflow** — prévision de la demande · prévisions réécrites dans Gold

TRANSVERSE

S'applique à toutes les couches

- **Qualité** — Great Expectations · contrats de données (YAML)
- **Traçabilité & catalogue** — OpenLineage · Marquez · documentation dbt
- **Supervision** — Prometheus · Grafana · Alertmanager
- **Sécurité & RGPD** — droits par rôle · journal d'audit · pseudonymisation
- **Industrialisation** — Git · Docker Compose · GitHub Actions