NeoRetail — Flux de données

① Ingestion batch

Airflow · chaque nuit à 02:00
ventes, commandes, retours, référentiels, CDC clients

Dépôt du fichier — zone d'atterrissage `landing/<source>/dt=AAAA-MM-JJ`
→ **Attente du fichier** — le DAG patiente jusqu'à l'arrivée du fichier du jour
→ **Contrôle du contrat** — colonnes, types, clés conformes au contrat YAML ?
→ **Chargement Bronze** — remplacement de la partition du jour (pas de doublon)
→ **Contrôle de complétude** — lignes du fichier = lignes en Bronze ?
→ **Suite** — métriques publiées puis lancement de dbt

✔ Rejouable : relancer un jour donne le même résultat ✔ Reprise : 3 nouvelles tentatives en cas d'erreur ✔ Rattrapage possible sur tout l'historique

② Ingestion temps réel

clickstream · flux continu
1 topic, 1 consommateur

Producteur Python — rejoue le fichier clickstream à débit réglable
→ **Topic Redpanda** — `clickstream.events.v1` 6 partitions · clé = session
→ **Spark Structured Streaming** — micro-lots toutes les 30 s · point de reprise (checkpoint)
→ **Bronze** — `clickstream_events` événements valides
Quarantaine — `clickstream_dlq` messages illisibles

✔ Aucune perte ni doublon au redémarrage (checkpoint + écriture atomique) ✔ Délai cible : moins de 2 min entre l'événement et Bronze

③ Transformation

dbt sur Trino · après chaque chargement

Bronze — données brutes
→ **stg_ (Silver)** — typage, renommage, sans doublons, pseudonymisation
→ **int_ (Silver)** — règles métier, historique des clients (SCD2)
→ **dim_ / fct_ (Gold)** — schéma en étoile
→ **mart_ (Gold)** — indicateurs prêts pour la BI
→ **Superset** — tableaux de bord

✔ Contrôles Great Expectations à chaque passage de zone ✔ Lignes incohérentes mises en quarantaine, jamais supprimées

④ Prévision (ML)

MLflow · entraînement puis prévision quotidienne

Ventes Gold — quantités par jour et par catégorie
→ **Entraînement** — référence naïve, Prophet, XGBoost
→ **Suivi MLflow** — scores (MAPE < 15 %), meilleur modèle enregistré
→ **Prévision quotidienne** — job batch planifié par Airflow
→ **Gold** — `fct_sales_forecast` prévision vs réalisé