[Logo établissement]

Dossier d'architecture

Plateforme Data Omnicanale « NeoRetail »

Mise en situation professionnelle — M2 Data Engineer

Livrable L1 — version du jalon S0

Équipe : [noms des membres]

Dépôt Git : [lien]

Octobre 2026

Sommaire

1. 1. Contexte et objectifs
2. 2. Sources de données
3. 3. Architecture logique
4. 4. Architecture physique
5. 5. Zones du lakehouse
6. 6. Flux de données
7. 7. Modèle analytique Gold
8. 8. Catalogue de données et traçabilité (lineage)
9. 9. Sécurité et RGPD
10. 10. Qualité des données et contrats de données
11. 11. SLO, supervision et alertes — L7
12. 12. Environnements, CI/CD et exploitation
13. 13. Risques, dette et perspectives (V1)
14. 14. Décisions d'architecture (ADR)
15. Annexe A — Décisions d'architecture (ADR)
16. Annexe B — Profilage des données
17. Annexe C — Dictionnaire de données des sources

Liste des figures

- Figure 1 — Architecture logique
- Figure 2 — Architecture physique (Docker Compose)
- Figure 3 — Flux de données
- Figure 4 — Schéma en étoile des ventes (zone Gold)

Version	Jalon S0 — document mis à jour à chaque jalon (S0 → S8)
Statut	Validé en cadrage
Périmètre	Lakehouse Bronze / Silver / Gold, batch + streaming, qualité, ML, BI, observabilité
Date	21/10/2026
Format livré	`docs/L1_dossier_architecture.pdf` (généré par `scripts/generer_documentation.py`)

1. Contexte et objectifs

NeoRetail est une enseigne omnicanale (e-commerce web et mobile, marketplace, 200 magasins physiques). Les décisions opérationnelles (stocks, prix, promotions) reposent aujourd'hui sur des sources cloisonnées. La plateforme vise à fournir **une vision unifiée et fiable des ventes, du parcours client et des retours**, ainsi qu'une **prévision de la demande** exploitable par les équipes métier.

Objectif pédagogique	Réponse de l'architecture
O1 — Architecture cloud-agnostic	Stockage objet S3 (MinIO), format ouvert Iceberg, moteurs interchangeables (§3, §4)
O2 — Pipelines batch et streaming	Airflow (batch idempotent), Redpanda + Spark Structured Streaming (§6)
O3 — Qualité et gouvernance	Great Expectations, contrats de données YAML, traçabilité OpenLineage, RGPD (§9, §10)
O4 — Modélisation	dbt : `stg_` → `int_` → `dim_` / `fct_`, schéma en étoile + couche sémantique (§7)
O5 — Cas d'usage ML	Prévision de la demande journalière, MLflow, prévision quotidienne en batch (§6.4)
O6 — Automatisation et exploitation	Docker Compose, GitHub Actions, Makefile, Prometheus / Grafana (§11, §12)

KPIs métier retenus pour la BI (L6)

1. **Chiffre d'affaires** net par canal et par période
2. **Panier moyen** (CA / nombre de commandes ou tickets)
3. **Taux de conversion** web (sessions avec achat / sessions)
4. **Taux de retour** (montant retourné / CA)
5. **Prévision vs réalisé** (erreur MAPE, cible < 15 %)

> Le KPI « rupture de stock » cité en exemple dans le sujet n'est pas réalisable : le pack de données ne contient aucune donnée d'inventaire. Ce point est tracé dans les risques et perspectives (§13).

2. Sources de données

Pack synthétique fourni (`neoretail_bigdata_pack`), période **01/01/2025 → 31/08/2026**, **3,37 M lignes / événements**. Profilage détaillé : profilage_donnees.md ; description de chaque colonne : dictionnaire_donnees.md.

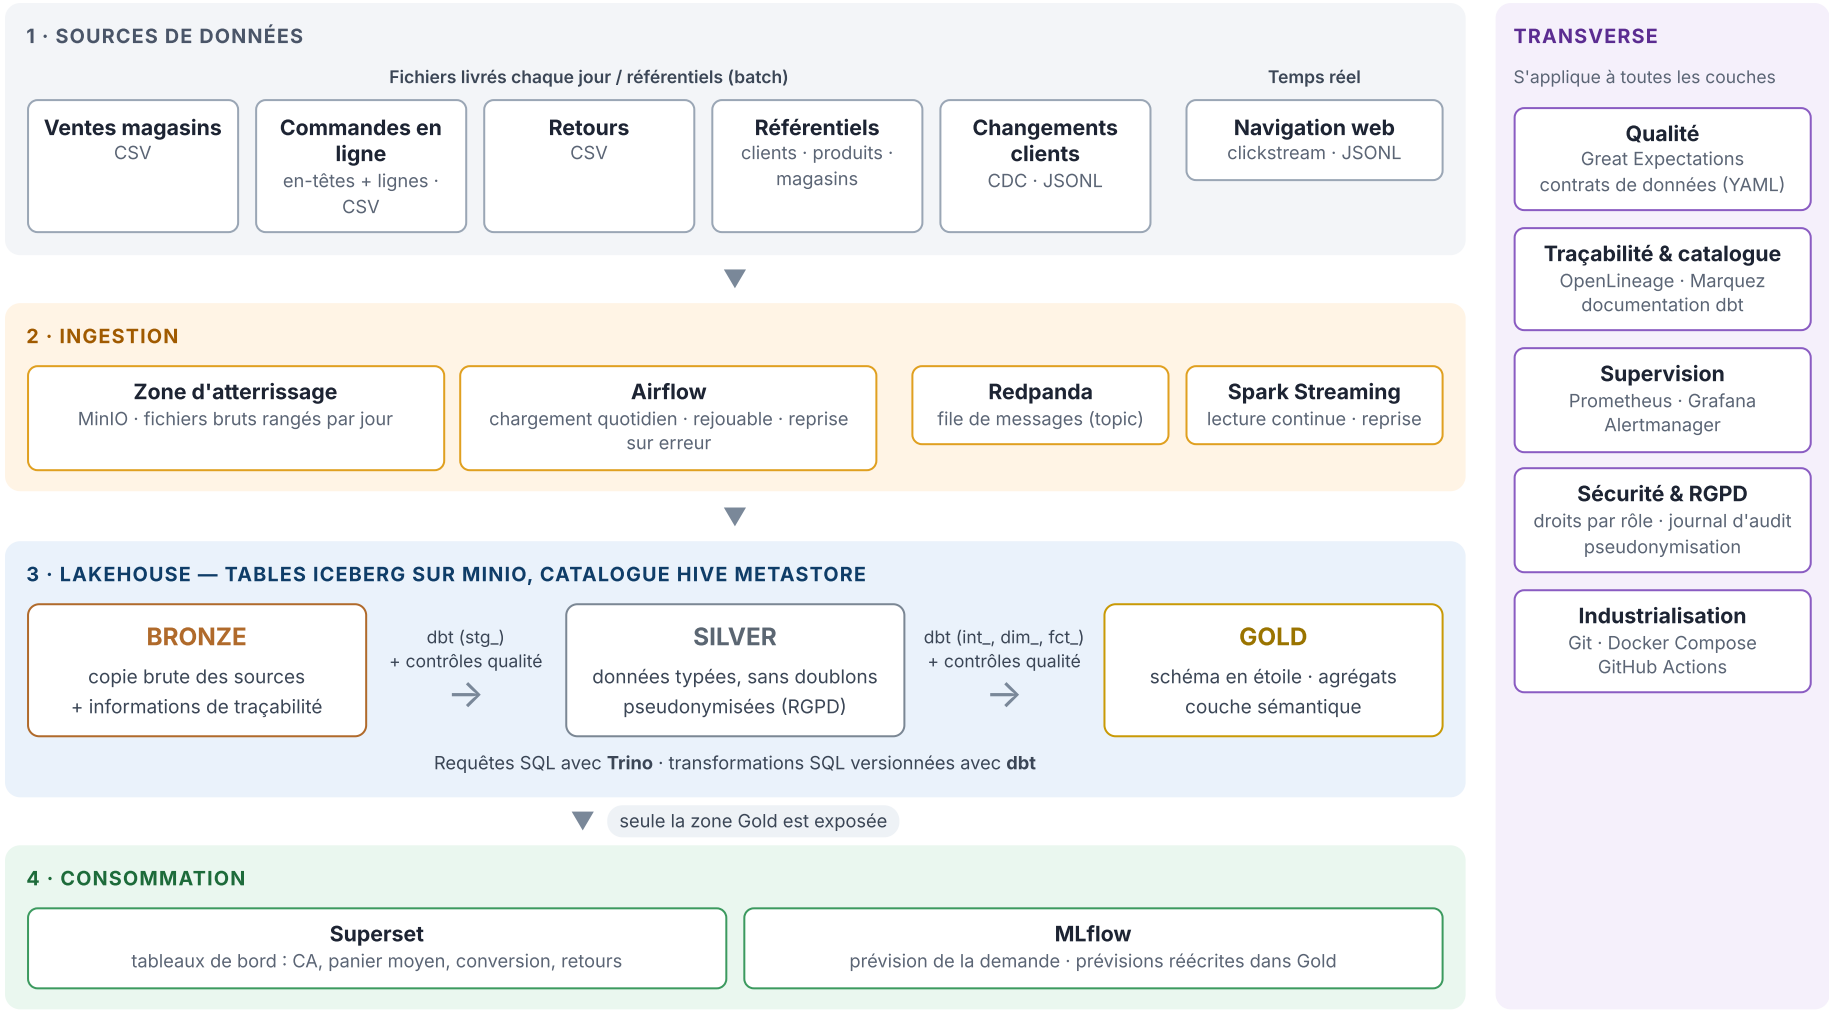
Source	Format	Volume	Mode d'ingestion	Rôle
`pos_sales`	CSV gz	500 000	Batch quotidien	Ventes magasins (ligne de ticket)
`orders`	CSV gz	500 000	Batch quotidien	En-têtes de commandes en ligne
`order_items`	CSV gz	1 000 000	Batch quotidien	Lignes de commandes en ligne
`returns`	CSV gz	100 000	Batch quotidien	Retours logistiques
`customers`	CSV gz	100 000	Batch (référentiel)	Référentiel clients (état initial)
`customer_updates`	JSONL gz	50 000	Batch (CDC)	Changements clients (U / D) → SCD2
`products`	CSV gz	20 000	Batch (référentiel)	Catalogue produits
`stores`	CSV gz	200	Batch (référentiel)	Référentiel magasins
`clickstream`	JSONL gz	1 000 000	**Streaming** (Redpanda)	Événements web / mobile
`gl_entries`	CSV gz	100 000	Batch (optionnel)	Écritures ERP — hors périmètre de la première version

Simulation du quotidien. Les fichiers sont livrés « en bloc ». Un script de découpage (S1) les redistribue dans la zone d'atterrissage par date métier (`landing/<source>/dt=YYYY-MM-DD/`). Le DAG Airflow est ainsi exécuté **par jour** et démontre le rattrapage d'historique (backfill), la reprise sur erreur et l'idempotence (rejouer = même résultat). Les référentiels sont chargés en totalité à chaque exécution (faible volume).

3. Architecture logique

Figure 1 — Architecture logique

docs/diagrammes/01_architecture_logique.pdf



Principes directeurs

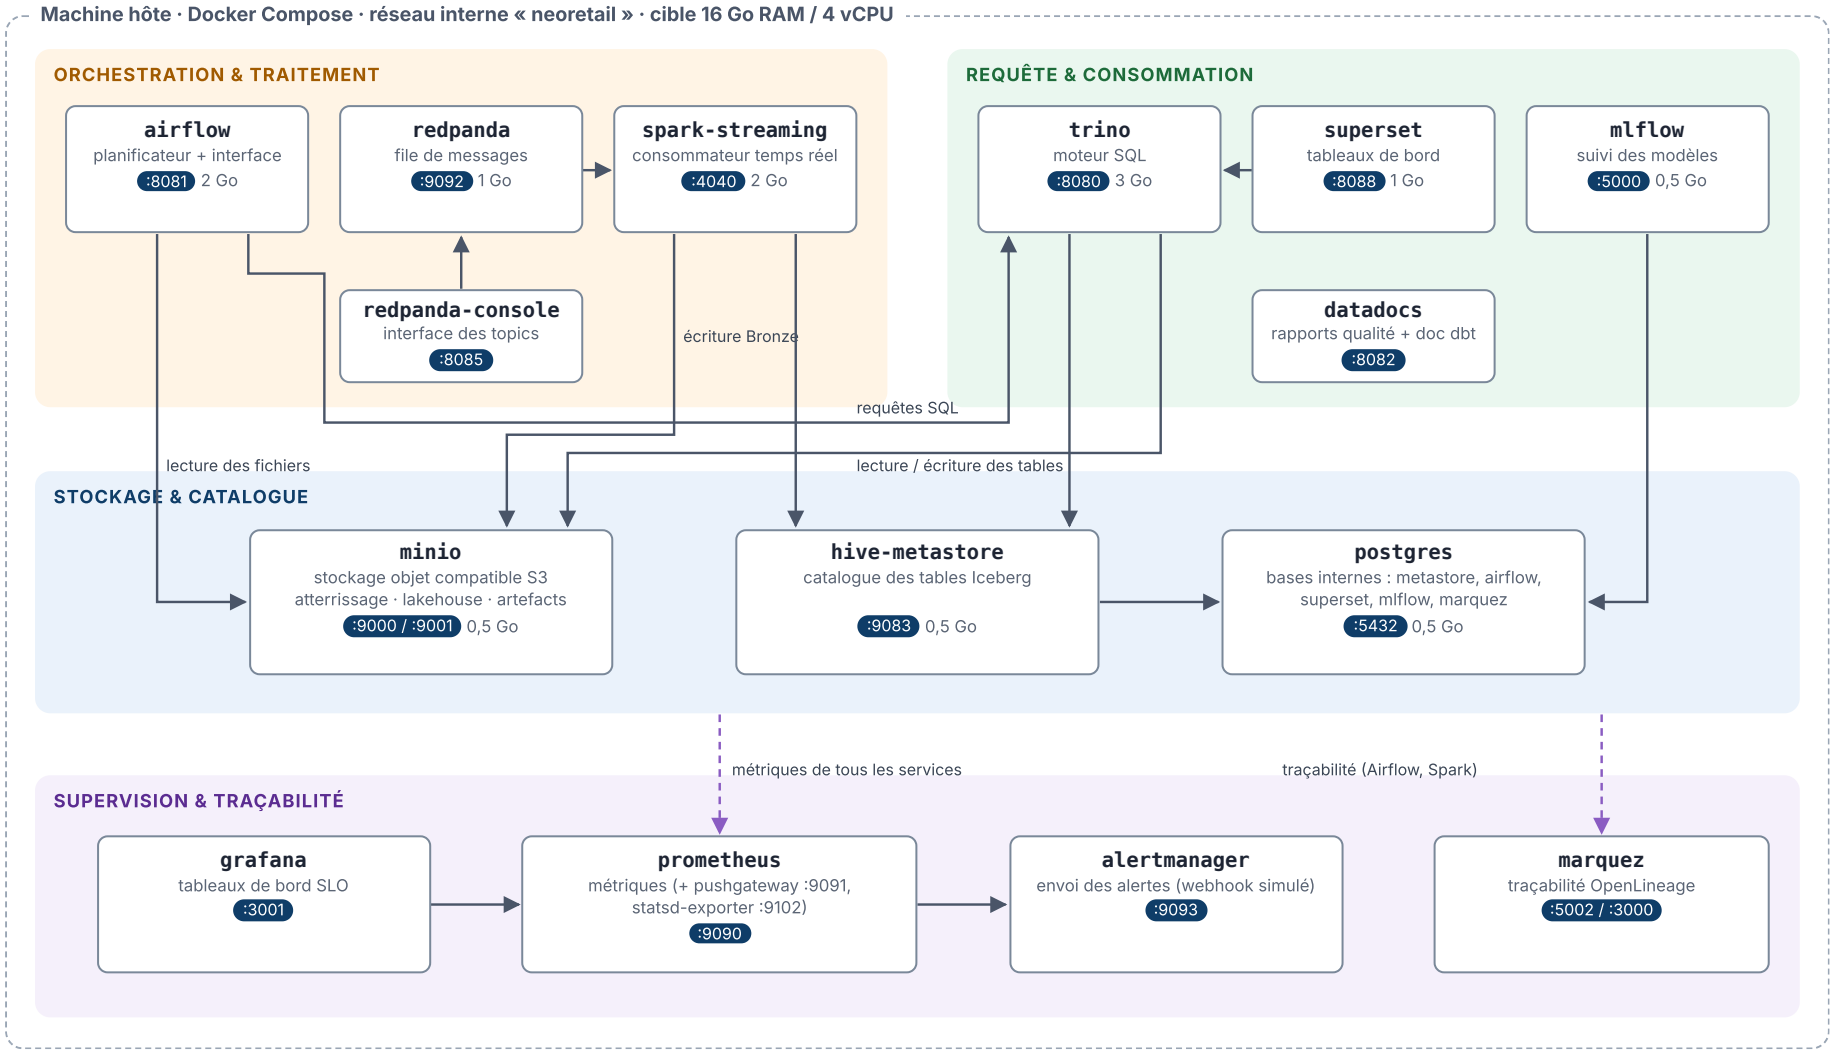
- **Séparation stockage / calcul** : les données vivent dans MinIO au format ouvert Iceberg ; Trino et Spark ne sont que des moteurs. Migration vers S3, GCS ou ADLS sans réécriture.
- **ELT** : chargement brut en Bronze, transformations en SQL versionné (dbt) dans le lakehouse.
- **Idempotence partout** : chaque écriture est rejouable sans doublon (remplacement de partition en batch, point de reprise + clé d'événement en streaming, fusion `merge` en dbt).
- **Qualité au plus tôt** : contrôles à chaque passage de zone, données non conformes en quarantaine plutôt que supprimées.
- **Protection des données dès la conception** : les identifiants personnels ne quittent jamais Bronze en clair.

4. Architecture physique

Déploiement local mono-hôte via **Docker Compose** (cible : 16 Go RAM, 4 vCPU). Chaque service correspond à un service managé équivalent dans le cloud (colonne de droite) : c'est ce qui garantit le caractère cloud-agnostic.

Figure 2 — Architecture physique (Docker Compose)

docs/diagrammes/02_architecture_physique.pdf



Service	Image (indicative)	Port	RAM	Rôle	Équivalent cloud
`minio`	minio/minio	9000 / 9001	0,5 Go	Stockage objet (landing, lakehouse, artefacts)	S3 / GCS / ADLS
`postgres`	postgres:16	5432	0,5 Go	Backends : metastore, Airflow, Superset, MLflow, Marquez	RDS / Cloud SQL
`hive-metastore`	apache/hive:4	9083	0,5 Go	Catalogue technique Iceberg	Glue Catalog
`trino`	trinodb/trino	8080	3 Go	Moteur SQL (dbt, GE, Superset)	Athena / Starburst
`redpanda`	redpandadata/redpanda	9092	1 Go	File de messages compatible Kafka	MSK / Confluent
`redpanda-console`	redpandadata/console	8085	0,2 Go	Interface : topics, retard du consommateur	—
`spark-streaming`	bitnami/spark (+ bibliothèques Iceberg)	4040	2 Go	Consommateur clickstream → Bronze	EMR / Dataproc
`airflow` (webserver + scheduler)	apache/airflow	8081	2 Go	Orchestration (LocalExecutor)	MWAA / Composer
`mlflow`	ghcr.io/mlflow/mlflow	5000	0,5 Go	Suivi des expériences + registre de modèles	SageMaker / Vertex
`superset`	apache/superset	8088	1 Go	BI	QuickSight / Looker
`marquez` (+ web)	marquezproject/marquez	5002 / 3000	0,7 Go	Traçabilité (OpenLineage)	Purview / Dataplex
`prometheus`	prom/prometheus	9090	0,3 Go	Métriques	CloudWatch / Managed Prometheus
`pushgateway`	prom/pushgateway	9091	0,1 Go	Métriques des traitements batch	—
`statsd-exporter`	prom/statsd-exporter	9102	0,1 Go	Métriques Airflow	—
`alertmanager`	prom/alertmanager	9093	0,1 Go	Alertes (webhook simulé)	SNS / PagerDuty
`grafana`	grafana/grafana	3001	0,3 Go	Tableaux de bord SLO	Managed Grafana
`datadocs`	nginx:alpine	8082	0,05 Go	Publication des rapports qualité GE + documentation dbt	Site statique S3

Total estimé : ~13 Go. Mode allégé possible (`make up-lite`) : sans Marquez ni Superset pendant le développement.

Organisation du stockage (MinIO)

```
s3://landing/<source>/dt=YYYY-MM-DD/<fichier>     # dépôt brut des fichiers sources
s3://lakehouse/warehouse/bronze.db/...            # tables Iceberg Bronze
s3://lakehouse/warehouse/silver.db/...            # tables Iceberg Silver
s3://lakehouse/warehouse/gold.db/...              # tables Iceberg Gold
s3://lakehouse/_checkpoints/clickstream/          # checkpoints Spark Streaming
s3://mlflow/                                      # artefacts MLflow (modèles, graphiques)
s3://datadocs/                                    # rapports qualité GE + documentation dbt
(site statique)
```

5. Zones du lakehouse

	Bronze	Silver	Gold
Contenu	Copie fidèle des sources	Données nettoyées, typées, conformes	Modèle analytique (étoile), agrégats (marts), prévisions
Écriture	Airflow (batch) / Spark (streaming)	dbt (`stg_` , `int_`)	dbt (`dim_` , `fct_` , `mart_`), traitement ML
Schéma	Source + colonnes techniques	Typé, renommé, normalisé	Clés de substitution, mesures, hiérarchies
Mode	Ajout / remplacement de partition	Incrémental (`merge`)	Incrémental (`merge`) ou table
Partitionnement	`_ingest_date`	Date métier (`days(event_ts)`)	Date métier (mois)
Données perso	En clair (pseudonymes source)	**Pseudonymisées (HMAC)**	Pseudonymisées, minimisées
Accès	`data_engineer` , comptes de service	+ `analyst` , `ml_engineer`	+ `bi_viewer`
Rétention	13 mois (expiration des snapshots)	Illimitée	Illimitée

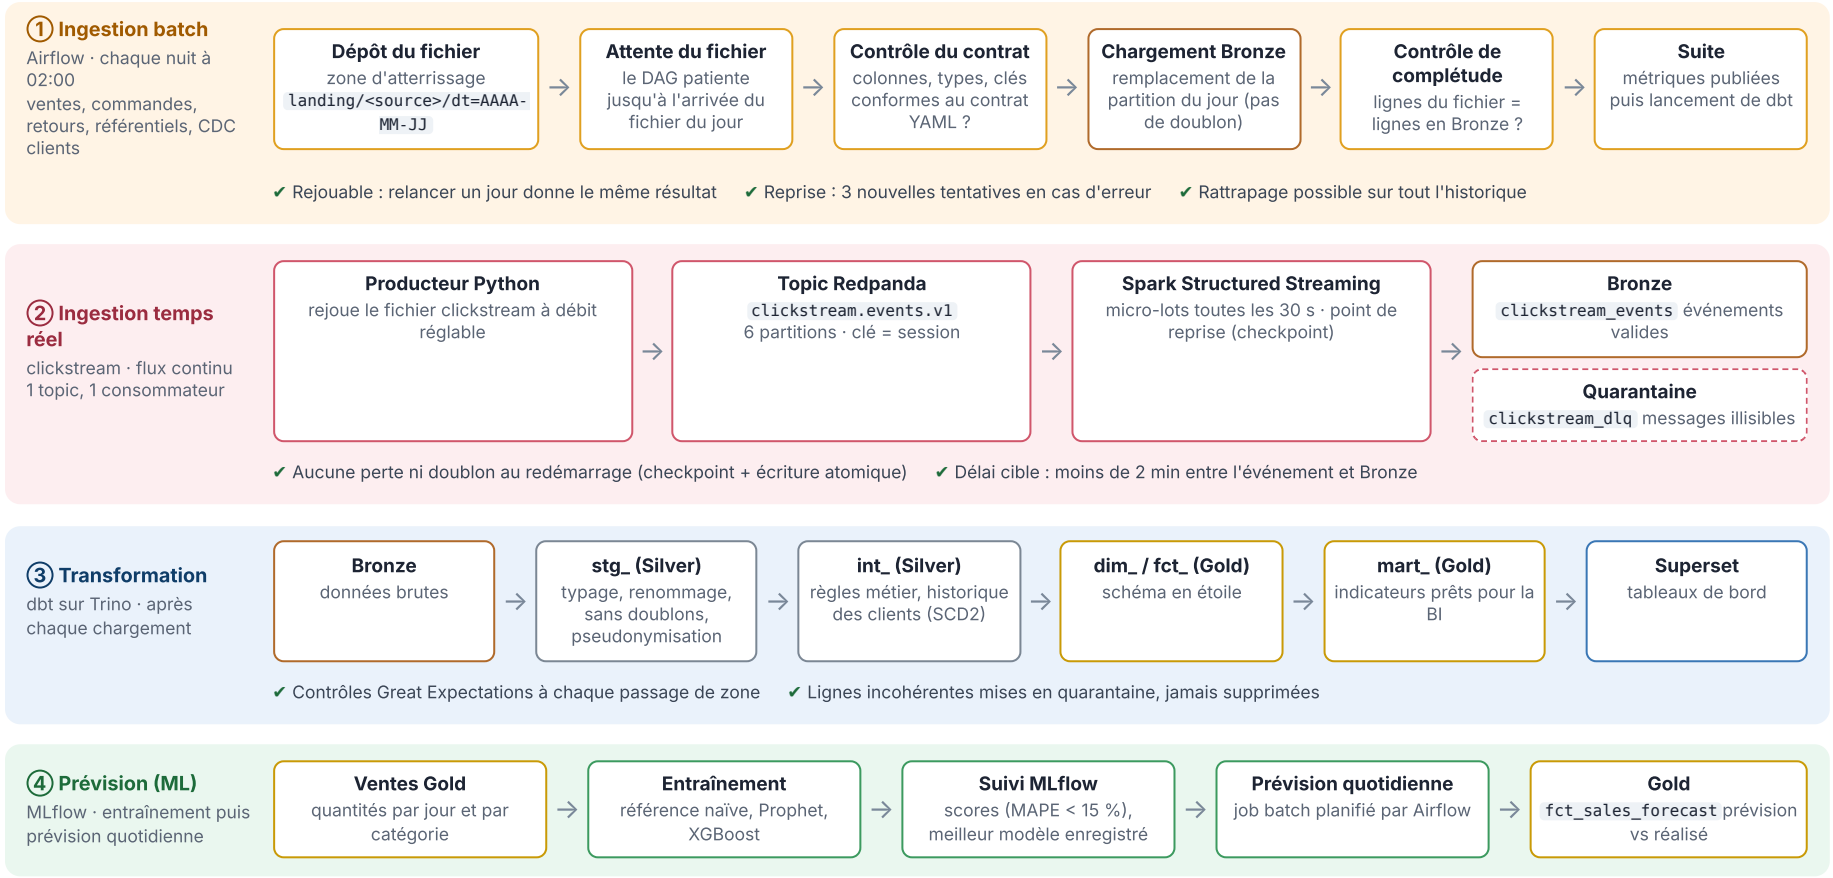
Colonnes techniques Bronze (toutes tables) : `_ingest_ts` , `_ingest_date` , `_source_file` , `_batch_id` (exécution Airflow ou micro-lot Spark), `_line_no` (ordre dans le fichier, indispensable pour départager les événements CDC de même horodatage).

Conventions de nommage. Catalogue Trino `lakehouse` , schémas `bronze` / `silver` / `gold` . Tables : `bronze.<source>` , `silver.stg_<source>` , `silver.int_<objet>` , `gold.dim_<objet>` , `gold.fct_<processus>` , `gold.mart_<domaine>` .

6. Flux de données

Le schéma ci-dessous présente les quatre flux de la plateforme ; chacun est détaillé dans les sous-sections suivantes.

Figure 3 — Flux de données docs/diagrammes/03_flux_de_donnees.pdf



6.1 Ingestion batch (Airflow) — L3

DAG d'ingestion quotidien (planifié à 02:00, rattrapage possible sur tout l'historique). Pour chaque source :

1. **Attente du fichier** du jour dans la zone d'atterrissage ;
2. **Contrôle du contrat** : colonnes, types et clés conformes au contrat de données YAML ;
3. **Chargement Bronze** : remplacement de la partition du jour (`_ingest_date`) ;
4. **Contrôle de complétude** : nombre de lignes du fichier = nombre de lignes chargées ;
5. **Publication des métriques** (lignes, durée, fraîcheur) ;
6. **Déclenchement de dbt** pour mettre à jour Silver et Gold.

Exigence	Mise en œuvre
Idempotence	Remplacement de la partition `_ingest_date` du jour : rejouer un jour remplace ses données sans doublon
Reprise	3 nouvelles tentatives avec délai croissant ; écritures atomiques (Iceberg) : un échec ne laisse pas d'état partiel
Rattrapage (backfill)	Chargement initial de tout l'historique (01/01/2025 → 31/08/2026), puis quotidien
Schéma versionné	Contrat YAML par source (`quality/contracts/`), rupture de schéma = échec explicite du contrôle du contrat
Sources	POS, commandes, lignes, retours (quotidien) + clients, CDC, produits, magasins (référentiels) — ≥ 2 sources exigées

6.2 Ingestion temps réel du clickstream (Redpanda → Spark → Bronze) — L3

Exigence	Mise en œuvre
1 topic, 1 consommateur	`clickstream.events.v1` , groupe de consommateurs `bronze-clickstream`
Ordre	Clé de partition = `session_id` → ordre garanti au sein d'une session
Fiabilité	Point de reprise Spark (checkpoint) + écriture atomique Iceberg → chaque événement écrit *exactement une fois* en Bronze
Messages invalides	JSON illisible ou champ obligatoire manquant → table de quarantaine (DLQ), jamais de perte silencieuse
Doublons	Dédoublonnage sur `event_id` en Silver (rejeu producteur possible)
Données tardives	Tolérance de retard d'1 h (watermark) sur `event_ts` pour les agrégats ; Bronze accepte tout
Métriques	Retard du consommateur, événements / s, délai événement → Bronze, taux de quarantaine

6.3 Transformation (dbt sur Trino) — L3

```
bronze.*  →  stg_*  (Silver : typage, renommage, pseudonymisation, dédoublonnage, indicateurs
qualité)
          →  int_*  (Silver : unions, règles métier, historisation SCD2 clients)
          →  dim_* / fct_*  (Gold : étoile)
          →  mart_*  (Gold : agrégats prêts pour la BI / couche sémantique)
```

Points clés :

- **SCD2 `dim_customer`** : état initial (`customers`) + événements CDC triés par `(change_ts, _line_no)`. Les mises à jour multiples d'un même client au même horodatage sont réduites à la dernière. Détection des changements par **empreinte (hash) des attributs suivis** (`region`, `segment`, `consent_marketing`). Une suppression (`op = D`) ferme la version courante et crée une version `is_deleted = true`.
- **Faits incrémentaux** : `materialized='incremental'`, stratégie `merge` sur la clé naturelle, fenêtre de relecture de 3 jours pour absorber les arrivées tardives.
- **Environnements** : profils dbt `dev` (schémas préfixés `dev_`) et `prod`, sélectionnés par variable d'environnement.

6.4 Cas d'usage ML — prévision de la demande — L5

Élément	Choix
Cible	Quantités vendues **par jour et par catégorie de produit**, tous canaux confondus
Données	`gold.fct_sales` agrégé (20 mois d'historique ≈ 600 points par série)
Référence	Modèle naïf saisonnier (ventes de J-7), pour mesurer l'apport des modèles
Modèles	Prophet (saisonnalités hebdo / annuelle) et XGBoost (lags, calendrier, promos)
Validation	Validation glissante dans le temps, horizon de 14 jours
Métriques	**MAPE (cible < 15 %)**, MAE, RMSE, enregistrées dans MLflow
Mise en production	Meilleur modèle enregistré dans le registre de modèles MLflow (`Staging` → `Production`)
Prévision	Traitement batch quotidien planifié par Airflow → `gold.fct_sales_forecast` (prévision + intervalle)
Suivi	Comparaison prévision vs réalisé en Gold → tableau de bord et alerte si le MAPE dérive

Choix motivé dans l'ADR-0007.

6.5 BI et couche sémantique — L6

- Superset interroge **uniquement Gold** via Trino (rôle `bi_viewer`).
- **Couche sémantique** : les indicateurs (CA, panier moyen, conversion, taux de retour, MAPE) sont définies **une seule fois** dans les `mart_*` dbt et déclarés comme métriques des jeux de données Superset. Les tableaux de bord sont déclarés en `exposures` dbt pour tracer le lien BI → Gold.

7. Modèle analytique Gold

7.1 Grain des faits

Fait	Grain	Sources	Mesures principales
`fct_sales`	**1 ligne = 1 article vendu** (ligne de commande en ligne ou ligne de ticket magasin)	`order_items` + `orders`, `pos_sales`	`qty`, `gross_amount`, `discount_amount`, `net_amount`, `tax_amount`, `cost_amount`, `margin_amount`
`fct_orders`	1 ligne = 1 commande en ligne	`orders` (+ agrégat lignes)	`nb_items`, `order_amount`, `is_cancelled`, `has_no_lines`
`fct_returns`	1 ligne = 1 retour	`returns`	`return_qty`, `return_amount`
`fct_web_events`	1 ligne = 1 événement	`clickstream`	`latency_ms`, compteur
`fct_web_sessions`	1 ligne = 1 session	`clickstream` agrégé	`nb_events`, étapes du tunnel d'achat, `is_converted`
`fct_sales_forecast`	1 ligne = 1 jour × 1 catégorie × 1 version de modèle	sortie du modèle ML	`forecast_qty`, `lower`, `upper`, `actual_qty`

Choix structurant : `fct_sales` **unifie** ventes en ligne et magasin avec une dimension canal (`web`, `mobile`, `marketplace`, `store`). C'est ce qui rend l'analyse omnicanale directe (ADR-0008). Les ventes magasin ont `store_sk` renseigné ; les ventes en ligne pointent vers le membre « En ligne » de `dim_store`.

7.2 Dimensions

Dimension	Type	Clé naturelle	Attributs / hiérarchie
`dim_date`	Type 0 (générée)	date	jour → semaine → mois → trimestre → année ; jour férié, week-end
`dim_customer`	**SCD2**	`customer_id` (pseudonymisé)	région, segment, consentement ; `valid_from`, `valid_to`, `is_current`, `is_deleted`
`dim_product`	SCD2 (structure prête, 1 version en source)	`product_id`	produit → sous-catégorie → catégorie ; marque, prix, coût, TVA
`dim_store`	SCD1	`store_id`	magasin → ville → format
`dim_channel`	Type 0	`channel`	canal → type (en ligne / physique)
`dim_promo`	Type 0	`promo_code`	taux de remise, famille de promo

Membres spéciaux : clé `-1` « Inconnu » (ex. : 28 % des tickets POS sans client) et `-2` « Non applicable » (ex. : magasin pour une vente en ligne).

7.3 Matrice faits × dimensions (bus matrix)

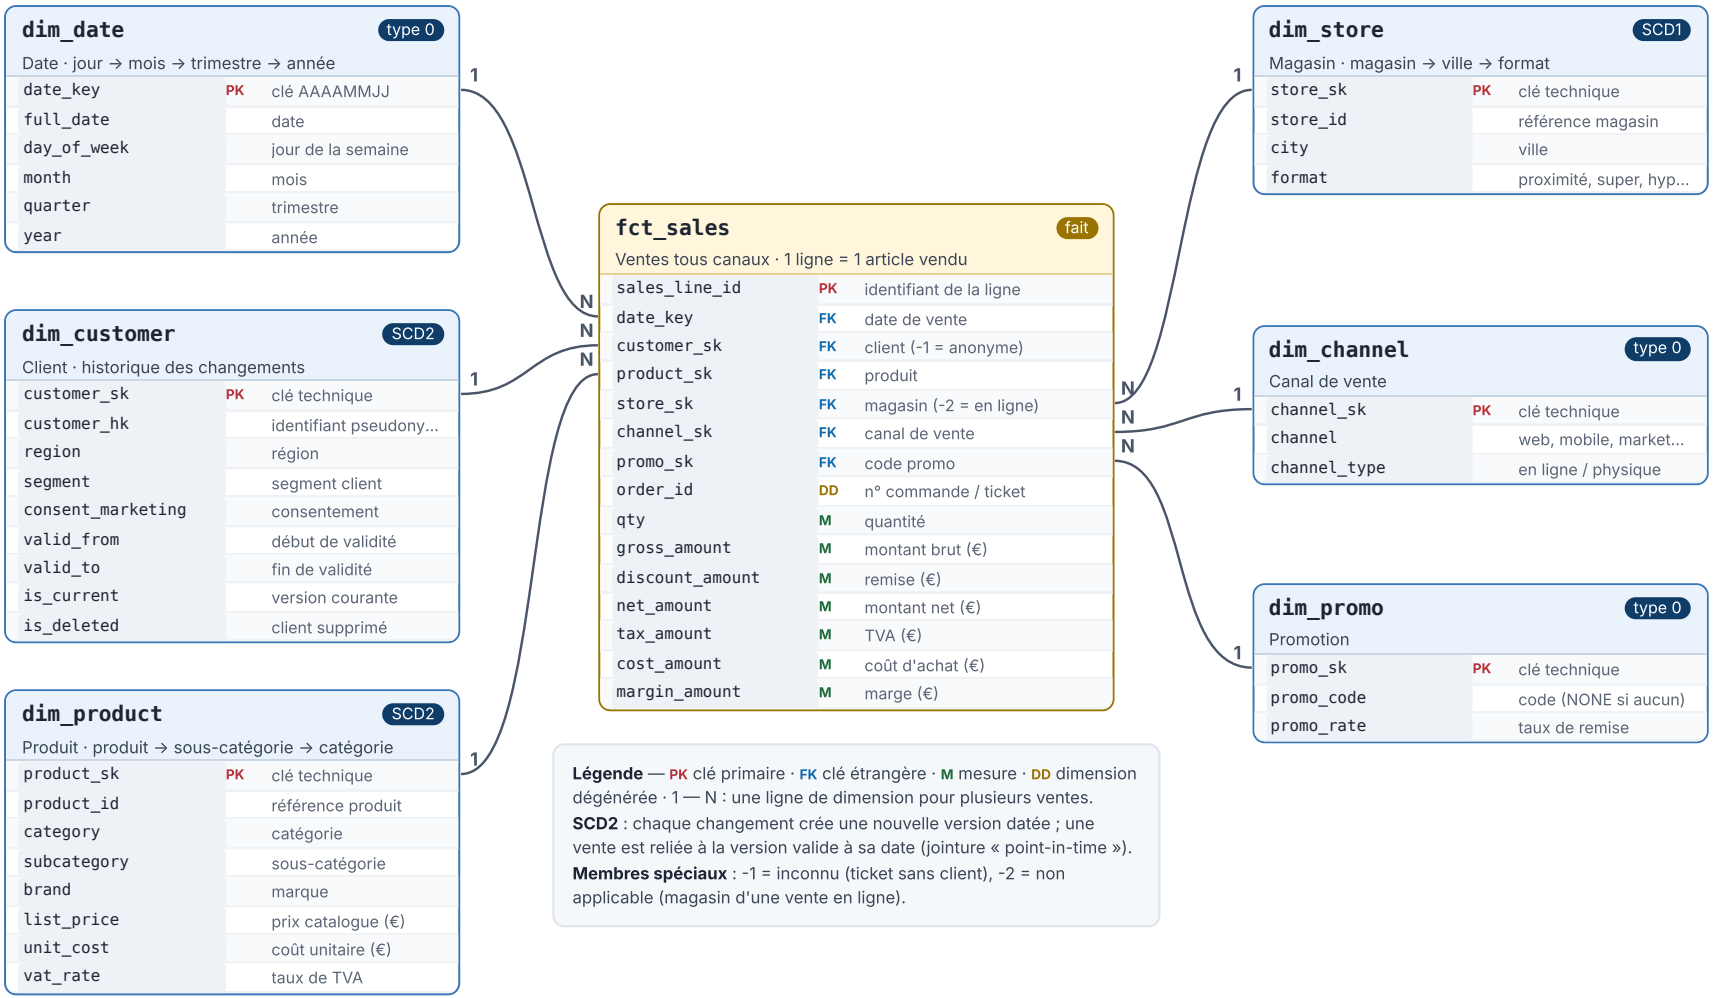
Fait \ Dimension	date	client	produit	magasin	canal	promo
`fct_sales`	✅	✅	✅	✅	✅	✅
`fct_orders`	✅	✅			✅	✅

Fait \ Dimension	date	client	produit	magasin	canal	promo
`fct_returns`	✅	✅	✅		✅	
`fct_web_events`	✅	✅	✅		✅	
`fct_web_sessions`	✅	✅			✅	
`fct_sales_forecast`	✅		✅ (catégorie)			

7.4 Schéma en étoile (cœur des ventes)

Figure 4 — Schéma en étoile des ventes (zone Gold)

docs/diagrammes/04_schema_etoile.pdf



La jointure `fct_sales → dim_customer` est **point-in-time** : la version client retenue est celle valide à la date de vente (`sale_ts` entre `valid_from` et `valid_to`). Les ventes d'août 2026 pointent donc vers les versions issues du CDC du 01/08/2026 : c'est la preuve visible du SCD2.

8. Catalogue de données et traçabilité (lineage)

Besoin	Outil	Contenu
Catalogue technique	Hive Metastore	Tables Iceberg, schémas, partitions, snapshots
Catalogue métier	Documentation dbt (publiée sur `datadocs`)	Description de chaque table / colonne, tests, propriétaires
Dictionnaire de données	`docs/dictionnaire_donnees.md` : sources (S0), puis complété avec Silver / Gold depuis les YAML dbt	Définition, type, unité, source, sensibilité RGPD
Traçabilité des traitements	OpenLineage (Airflow + Spark) → **Marquez**	Fichier source → Bronze → traitements → Silver → Gold
Traçabilité des modèles	Documentation dbt (graphe des modèles) + `exposures`	Tables Gold → tableaux de bord Superset
Historique	Snapshots Iceberg (retour à une version passée)	Audit et retour arrière d'une table

9. Sécurité et RGPD

9.1 Classification des données

Colonne	Source	Classe	Traitement
`customer_id`	customers, orders, pos, clickstream, CDC	Identifiant indirect	**HMAC-SHA256 avec sel secret** dès `stg_` → `customer_hk`
`email_pseudo`	customers	Donnée personnelle (pseudonymisée source)	**Non propagée** au-delà de Bronze (minimisation)
`phone_pseudo`	customers	Donnée personnelle (pseudonymisée source)	**Non propagée** au-delà de Bronze (minimisation)
`consent_marketing`	customers, CDC	Base légale	Conservée, historisée (SCD2)
`region` , `segment`	customers	Quasi-identifiant faible	Conservées (granularité régionale)
`session_id`	clickstream	Identifiant technique	Conservé (pas de lien direct à une personne)

Le sel HMAC est stocké hors code (variable d'environnement / secret Airflow, jamais versionné). Il est commun à toutes les sources pour préserver les jointures.

9.2 Gestion des accès (RBAC)

Contrôle d'accès **fichier** de Trino (`rules.json`), rôles Superset, policies MinIO.

Rôle	Bronze	Silver	Gold	Écriture
`data_engineer`	R	R	R	Bronze, Silver, Gold (via comptes de service)
`svc_airflow` / `svc_streaming`	R/W	R/W	R/W	Pipelines uniquement
`ml_engineer`	—	R	R	`gold.fct_sales_forecast`
`analyst`	—	R	R	—
`bi_viewer` (Superset)	—	—	R	—

9.3 Journalisation et droits des personnes

- **Audit des requêtes** : event listener Trino → log de chaque requête (utilisateur, tables, horodatage), conservé 12 mois.
- **Audit stockage** : logs d'accès MinIO ; logs de tâches Airflow.
- **Droit à l'effacement** : un événement CDC `D` déclenche la clôture logique en Silver / Gold. Une procédure de purge (`make gdpr-erase ID=...`) supprime les lignes Bronze concernées (`DELETE` Iceberg) puis exécute `expire_snapshots` pour effacer physiquement l'historique.
- **Rétention** : Bronze 13 mois, snapshots Iceberg 7 jours.

10. Qualité des données et contrats de données

Niveau	Outil	Exemples de règles
Contrat d'entrée	Contrat de données YAML par source	Colonnes, types, nullabilité, clé, propriétaire, SLA de livraison
Bronze → Silver	Great Expectations	Unicité des clés, domaines (`channel` , `status` , `event_type`), % NULL, volumétrie vs J-1
Silver → Gold	Tests dbt + GE	Intégrité référentielle, `net_amount ≈ qty × prix × (1 − remise)` à ±0,10 €, montants ≥ 0
Gold	GE + tests dbt	Couverture **> 80 % des tables Gold**, fraîcheur, réconciliation CA Gold vs Bronze

Anomalies identifiées au profilage et traitement retenu (détail : profilage_donnees.md) :

Anomalie	Volume	Traitement
Tickets POS sans client	139 630 (28 %)	Membre `-1` « Client anonyme »
Commandes sans ligne d'article	67 689	Conservées dans `fct_orders` , indicateur `has_no_lines`
Retours : couple commande × produit absent des ventes	99 991	Rattachement au grain commande, indicateur `line_not_found`
Retours datés avant la commande	49 809	Quarantaine (`silver.quarantine_returns`) + alerte GE
Écart d'arrondi `net_amount`	110 205 lignes (< 0,10 €)	Tolérance ±0,10 € ; `net_amount` source fait foi
CDC : MAJ multiples au même horodatage	9 043 clients	Ordre de fichier (`_line_no`) pour départager
`region` NULL	100	Valeur « Non renseigné » + suivi du taux NULL

Rapports qualité GE et documentation dbt publiés à chaque exécution sur `http://localhost:8082` .

11. SLO, supervision et alertes — L7

SLO	Indicateur	Cible	Alerte
Fraîcheur batch	Âge de la dernière partition Gold `fct_sales`	Données J-1 disponibles avant 07:00	> 30 h → critique
Latence streaming	Délai production → Bronze (p95)	< 2 min	> 5 min pendant 10 min
Fraîcheur web Gold	Âge de `fct_web_sessions`	< 90 min	> 3 h
Complétude	Lignes Bronze / lignes fichier source	100 %	< 100 % → critique
Rejets	Lignes en quarantaine (y compris DLQ) / total	< 1 %	> 1 %
Qualité	Contrôles GE critiques en succès sur Gold	100 %	Tout échec critique
Fiabilité des pipelines	Exécutions Airflow réussies (7 jours glissants)	≥ 99 %	Échec après les nouvelles tentatives
Performance ML	MAPE prévision vs réalisé (7 jours glissants)	< 15 %	> 20 %

Collecte : Airflow → StatsD exporter ; traitements batch, GE et dbt → Pushgateway ; Spark → `StreamingQueryListener` → Pushgateway ; Redpanda → point d'accès Prometheus natif. **Restitution** : tableau de bord Grafana « SLO plateforme ». **Alertes simulées** : règles Prometheus → Alertmanager → webhook (récepteur local qui journalise les alertes), démontré en soutenance par un incident provoqué.

12. Environnements, CI/CD et exploitation

Sujet	Mise en œuvre
Environnements	`dev` / `prod` séparés par `.env` + profils dbt + schémas préfixés
Démarrage	`make up` (Compose), `make seed` (dépôt des fichiers en zone d'atterrissage), `make demo` (exécution de bout en bout)
Intégration continue (GitHub Actions)	Contrôle de style (ruff, sqlfluff), tests unitaires Python, `dbt parse` + `dbt build` sur échantillon (DuckDB), validation des contrats de données, construction des images
Déploiement continu	Construction et étiquetage des images, publication de la documentation
Reproductibilité	Images versionnées, jeu de données de démarrage, `.env.sample`
Documentation	README d'orchestration, ADR, dictionnaire de données, procédures d'incident

13. Risques, dette et perspectives (V1)

Risque	Impact	Mitigation
Empreinte mémoire de la stack (~13 Go)	Démo instable sur poste léger	Mode `up-lite`, limites mémoire par service, démo sur la machine la mieux dotée
Compatibilité des versions (Spark / Iceberg / HMS / Trino)	Blocage S1-S2	Matrice de versions figée dès S1, tests de démarrage en CI
Incohérences des retours (dates, couples absents)	KPI taux de retour biaisé	Quarantaine + indicateurs, KPI calculé au grain commande, limite documentée
Absence de données de stock	KPI rupture impossible	Hors périmètre, perspective : flux d'inventaire magasin
`gl_entries` datées d'un seul jour	Pas d'analyse financière temporelle	Hors périmètre de la première version, agrégat finance en option

14. Décisions d'architecture (ADR)

ADR	Décision
0001	Apache Iceberg comme format de table
0002	MinIO + Hive Metastore pour le stockage et le catalogue
0003	Trino comme moteur SQL unique (dbt, GE, BI)
0004	Redpanda + Spark Structured Streaming
0005	dbt-trino pour les transformations
0006	Pseudonymisation HMAC en entrée de Silver
0007	Prévision de la demande comme cas d'usage ML
0008	Fait de ventes unifié omnicanal
0009	Quarantaine et indicateurs plutôt que suppression

Annexe A — Décisions d'architecture (ADR)

ADR-0001 — Apache Iceberg comme format de table

- **Statut** : accepté
- **Date** : 20/10/2026

Contexte

Le sujet impose un lakehouse Delta, Iceberg ou Hudi avec un metastore « Hive/Glue-like ». Les tables doivent être lisibles par Spark (streaming) et par un moteur SQL (dbt, BI).

Décision

Apache Iceberg (fichiers Parquet), catalogué dans Hive Metastore.

Justification

- Support natif et mature côté Trino **et** Spark, sans dépendance à un éditeur.
- Évolution de schéma et de partitionnement sans réécriture, partitionnement implicite (`days(event_ts)`).
- Snapshots (retour à une version passée) : audit, retour arrière, purge RGPD via `expire_snapshots`.
- Delta est plus lié à Spark / Databricks côté écosystème ; Hudi est plus complexe à opérer pour un usage majoritairement batch.

Conséquences

- Maintenance à prévoir : compaction (`optimize`) et expiration des snapshots planifiées dans Airflow.

ADR-0002 — MinIO + Hive Metastore pour le stockage et le catalogue

- **Statut** : accepté
- **Date** : 20/10/2026

Contexte

L'architecture doit être cloud-agnostic et tourner en local.

Décision

MinIO (API S3) pour tout le stockage objet, **Hive Metastore** (backend PostgreSQL) comme catalogue technique.

Justification

- MinIO expose l'API S3 : le même code fonctionne sur AWS S3, et via passerelle sur GCS ou ADLS.
- Hive Metastore est l'équivalent local de AWS Glue Catalog, explicitement demandé par le sujet.
- Les deux sont supportés nativement par Trino, Spark et PyIceberg.

Conséquences

- Un PostgreSQL unique héberge plusieurs bases (metastore, Airflow, Superset, MLflow, Marquez) pour limiter l'empreinte ; en production, ces bases seraient séparées.

ADR-0003 — Trino comme moteur SQL unique

- **Statut** : accepté
- **Date** : 20/10/2026

Contexte

dbt, Great Expectations et Superset ont besoin d'un moteur SQL sur les tables Iceberg.

Décision

Trino sert de point d'accès SQL unique au lakehouse.

Justification

- Un seul moteur pour transformer (dbt-trino), contrôler (GE via SQLAlchemy) et restituer (Superset) : une seule politique d'accès.
- Contrôle d'accès par fichier (RBAC) et event listener pour l'audit des requêtes.
- Plus léger à opérer qu'un Spark Thrift Server pour des requêtes interactives.

Conséquences

- Spark reste utilisé uniquement pour le streaming. Mémoire de Trino à borner (3 Go) en local.

ADR-0004 — Redpanda + Spark Structured Streaming

- **Statut** : accepté
- **Date** : 20/10/2026

Contexte

Le sujet impose Kafka (ou Redpanda) avec un consommateur Python ou Spark Structured Streaming et une écriture en zone Bronze.

Décision

Redpanda comme file de messages, **Spark Structured Streaming** comme consommateur, écriture en Iceberg Bronze.

Justification

- Redpanda : API Kafka 100 % compatible, binaire unique sans ZooKeeper, empreinte mémoire bien plus faible.
- Spark Structured Streaming : points de reprise (checkpoints) + écritures atomiques Iceberg → chaque événement écrit exactement une fois en Bronze.

- Gestion native des données en retard (watermark) et des messages invalides (routage vers une table de quarantaine).

Conséquences

- Spark ajoute environ 2 Go de RAM et une dépendance aux bibliothèques Iceberg / Kafka, dont il faut figer les versions.

ADR-0005 — dbt-trino pour les transformations

- **Statut** : accepté
- **Date** : 20/10/2026

Contexte

Les transformations vont jusqu'à un schéma en étoile Gold, avec tests, documentation et traçabilité (lineage).

Décision

dbt (adaptateur Trino), couches `stg_` → `int_` → `dim_` / `fct_` → `mart_`.

Justification

- SQL versionné, testable (tests génériques + singuliers) et documenté.
- La documentation dbt fournit le catalogue métier et la traçabilité ; les `exposures` relient Gold aux tableaux de bord.
- Chargement incrémental par fusion (`merge`) sur Iceberg : idempotence et performances.
- Profils `dev` / `prod` pour la séparation des environnements.

Conséquences

- Le SCD2 clients est implémenté en modèle incrémental dédié plutôt qu'en `snapshot` dbt, car le CDC fourni contient plusieurs changements au même horodatage.

ADR-0006 — Pseudonymisation HMAC en entrée de Silver

- **Statut** : accepté
- **Date** : 20/10/2026

Contexte

Le RGPD impose minimisation et pseudonymisation. `customer_id` est présent dans 5 sources ; e-mail et téléphone (déjà pseudonymisés par la source) dans le référentiel clients.

Décision

`customer_id` est remplacé par `customer_hk = HMAC-SHA256(sel, customer_id)` dans **tous** les modèles `stg_`. E-mail et téléphone ne sont **pas** propagés au-delà de Bronze.

Justification

- Le HMAC avec sel secret empêche la ré-identification par force brute (contrairement à un hash simple).
- Un sel commun à toutes les sources préserve les jointures.
- Bronze, seule zone contenant des identifiants en clair, est réservée aux ingénieurs et comptes de service.

Conséquences

- Rotation du sel = recalcul complet de Silver / Gold (documenté dans un runbook).

ADR-0007 — Prévision de la demande comme cas d'usage ML

- **Statut** : accepté
- **Date** : 20/10/2026

Contexte

Le sujet propose la prévision de la demande ou l'attrition des clients (churn). Les données de retours sont incohérentes (50 % datés avant la commande) ; les données clients sont peu riches (une seule date d'inscription).

Décision

Prévision des quantités vendues par jour et par catégorie, tous canaux.

Justification

- 20 mois d'historique de ventes propres : base solide pour un modèle de séries temporelles.
- Lien direct avec l'enjeu métier (stocks, promotions) et avec le KPI de la grille (MAPE < 15 %).
- L'attrition (churn) souffrirait de l'absence de signal fiable (dates d'inscription identiques, pas de désabonnement explicite).

Conséquences

- Une référence naïve saisonnière (ventes de J-7) est obligatoire pour démontrer l'apport du modèle.

ADR-0008 — Fait de ventes unifié omnicanal

- **Statut** : accepté
- **Date** : 20/10/2026

Contexte

Les ventes proviennent de deux systèmes : commandes en ligne (en-tête + lignes) et tickets de caisse.

Décision

Un fait unique `fct_sales` au grain de l'article vendu, alimenté par les deux sources, avec une dimension canal (`web`, `mobile`, `marketplace`, `store`). Un fait complémentaire `fct_orders` porte le grain commande.

Justification

- Les KPIs omnicanaux (CA, mix canal, panier) se calculent sans `UNION` côté BI.
- Grain identique et mesures conformes (`qty`, `net_amount`, remise) dans les deux sources.

Conséquences

- Les attributs spécifiques (statut de commande, magasin) sont portés par des dimensions avec membres « Non applicable ».

ADR-0009 — Quarantaine et indicateurs plutôt que suppression

- **Statut** : accepté
- **Date** : 20/10/2026

Contexte

Le profilage révèle des anomalies : tickets sans client, commandes sans lignes, retours incohérents, écarts d'arrondi.

Décision

Aucune ligne n'est supprimée silencieusement : les lignes **inexploitables** vont en table de quarantaine, les lignes **exploitables mais imparfaites** sont conservées avec un indicateur qualité.

Justification

- Traçabilité complète : chaque écart est mesurable et expliqué.
- Les KPIs restent réconciliables avec les sources (CA Gold vs Bronze).
- Les taux de quarantaine alimentent directement les SLO de qualité.

Conséquences

- Les seuils (ex. tolérance ±0,10 € sur `net_amount`) sont versionnés dans les contrats de données.

Annexe B — Profilage des données

Profilage des données sources

Pack `neoretail_bigdata_pack` (synthétique, pseudonymisé). Résultats reproductibles avec :

```
python scripts/profilage_donnees.py data/neoretail_bigdata_pack
```

1. Volumes et période

Source	Lignes	Période	Colonnes avec NULL
stores	200	—	aucune
products	20 000	—	`effective_to` (100 %, attendu : version courante)
customers	100 000	`signup_date` = 01/01/2025 pour tous	`region` (0,10 % = 100 lignes)
orders	500 000	01/01/2025 → 31/08/2026	aucune
order_items	1 000 000	(via orders)	aucune
pos_sales	500 000	01/01/2025 → 31/08/2026	`customer_id` (27,93 %)
returns	100 000	01/01/2025 → 31/08/2026	aucune
gl_entries	100 000	01/01/2025 uniquement	aucune
clickstream	1 000 000	01/01/2025 → 31/08/2026	`product_id` (52,07 %, attendu : pages sans produit)
customer_updates (CDC)	50 000	`change_ts` = 01/08/2026 12:00 pour tous	aucune

2. Clés et intégrité référentielle

- **Unicité** : aucune clé primaire en doublon (stores, products, customers, orders, order_items, pos_sales, returns, gl_entries, clickstream).
- **Intégrité référentielle** : 0 orphelin sur toutes les relations testées (order_items → orders / products, orders → customers, pos_sales → stores, returns → orders, clickstream → customers).

3. Domaines de valeurs

Colonne	Valeurs
`orders.channel`	web (224 641), mobile (199 616), marketplace (75 743)
`orders.status`	delivered (409 989), shipped (50 148), paid (24 829), cancelled (15 034)
`orders.promo_code`	NONE, LOYAL5, WELCOME10, FLASH15, SUMMER20
`order_items.discount_rate`	0, 0,05, 0,10, 0,15, 0,20
`clickstream.event_type`	page_view, product_view, search, add_to_cart, checkout, purchase
`returns.reason`	late, wrong_item, damaged, size_issue, not_as_expected, other (≈ équirépartis)
`customers.segment`	Standard, Premium, Etudiant, Entreprise

Colonne	Valeurs
`customers.region`	IDF, Sud-Est, Ouest, Sud-Ouest, Nord, Est, Centre, International, NULL
`stores.format`	proximity, super, hyper, outlet
`customer_updates.op`	U (49 014), D (986)

4. Anomalies et décisions

#	Anomalie	Volume	Impact	Décision
A1	Tickets POS sans `customer_id`	139 630	Ventes anonymes en magasin	Membre `-1` « Client anonyme » dans `dim_customer`
A2	Commandes sans aucune ligne d'article	67 689	Pas de montant	Conservées dans `fct_orders`, indicateur `has_no_lines` ; exclues du panier moyen
A3	Retours dont le couple (commande, produit) n'existe pas dans `order_items`	99 991	Rattachement ligne impossible	Retour rattaché au grain commande, indicateur `line_not_found`
A4	Retours datés avant la commande	49 809	Incohérence temporelle	Quarantaine `silver.quarantine_returns` + règle GE
A5	Écart `net_amount` vs `qty × unit_price × (1 − discount_rate)`	45 433 (web) + 64 772 (POS)	Arrondi au centime (aucun écart > 0,10 €)	Tolérance ±0,10 € ; `net_amount` source fait foi
A6	CDC : plusieurs mises à jour d'un même client au même `change_ts`	9 043 clients	SCD2 non déterministe	Départage par ordre de fichier (`_line_no`), dernière valeur retenue
A7	`region` NULL	100	Segmentation incomplète	Valeur « Non renseigné » + suivi du taux NULL
A8	`gl_entries.posting_date` et `customers.signup_date` sur une seule date	100 %	Pas d'analyse temporelle	Hors périmètre de la première version (finance) ; pas d'ancienneté client exploitable
A9	Produits : une seule version (`is_current = true` partout)	20 000	SCD2 produit non démontrable	Structure SCD2 prête ; démonstration SCD2 sur les clients

5. Ordres de grandeur

- CA net en ligne (`order_items`) : **138,0 M€** ; CA net magasins (`pos_sales`) : **91,3 M€**.
- Clickstream : 59 702 événements `purchase` pour 1 M d'événements. Le clickstream n'est **pas relié aux commandes** (pas d'`order_id`) : la conversion se mesure au niveau session.

Annexe C — Dictionnaire de données des sources

Dictionnaire de données — sources NeoRetail

Description de chaque colonne des fichiers sources du pack `neoretail_bigdata_pack`. Ce dictionnaire sera complété avec les tables Silver et Gold à partir des fichiers YAML dbt (S3-S4).

Légende de la colonne RGPD :

- **Identifiant indirect** : permet de relier des données à une personne ; remplacé par un code pseudonyme (HMAC) dès la zone Silver.
- **Donnée personnelle** : déjà pseudonymisée par la source ; conservée uniquement en Bronze (accès restreint), jamais propagée au-delà (minimisation).
- **—** : donnée non personnelle.

Les exemples sont tirés de la première ligne de chaque fichier ; les données personnelles sont masquées.

Sommaire

1. Ventes magasins — `pos_sales`
2. Commandes en ligne (en-têtes) — `orders`
3. Lignes de commandes en ligne — `order_items`
4. Retours — `returns`
5. Référentiel clients — `customers`
6. Changements clients (CDC) — `customer_updates`
7. Catalogue produits — `products`
8. Référentiel magasins — `stores`
9. Navigation web (clickstream) — `clickstream`

1. Ventes magasins — `pos_sales`

Une ligne par article scanné en caisse dans un magasin NeoRetail.

Propriété	Valeur
Fichier source	`raw/pos/pos_sales.csv.gz` (CSV compressé)
Volume	500 000 lignes
Mode d'ingestion	batch, livraison quotidienne
Clé primaire	`sale_id`
Date métier	`sale_ts`
Propriétaire	Équipe Magasins

Colonne	Type	Obligatoire	Description	Règles / valeurs autorisées	RGPD	Exemple
`sale_id`	texte	oui	Identifiant de la ligne de ticket	« PS » + 10 chiffres	—	`PS0000000001`

Colonne	Type	Obligatoire	Description	Règles / valeurs autorisées	RGPD	Exemple
`sale_ts`	horodatage	oui	Horodatage du passage en caisse	—	—	`2025-11-14T21:12:20`
`store_id`	texte	oui	Magasin	« S » + 4 chiffres	—	`S0121`
`customer_id`	texte	non	Client carte fidélité (NULL = client anonyme)	« C » + 8 chiffres	Identifiant indirect	`C00074559`
`product_id`	texte	oui	Produit	« P » + 7 chiffres	—	`P0001471`
`qty`	entier	oui	Quantité	≥ 1	—	`6`
`unit_price`	décimal	oui	Prix unitaire	≥ 0 ; unité : EUR	—	`18.23`
`discount_rate`	décimal	oui	Taux de remise	≥ 0 ; ≤ 1	—	`0.00`
`net_amount`	décimal	oui	Montant net de la ligne	≥ 0 ; unité : EUR	—	`109.39`

2. Commandes en ligne (en-têtes) — `orders`

Une ligne par commande passée sur le site web, l'application mobile ou la marketplace.

Propriété	Valeur
Fichier source	`raw/orders/orders.csv.gz` (CSV compressé)
Volume	500 000 lignes
Mode d'ingestion	batch, livraison quotidienne
Clé primaire	`order_id`
Date métier	`order_ts`
Propriétaire	Équipe E-commerce

Colonne	Type	Obligatoire	Description	Règles / valeurs autorisées	RGPD	Exemple
`order_id`	texte	oui	Identifiant de commande	« O » + 10 chiffres	—	`O0000000001`
`order_ts`	horodatage	oui	Horodatage de la commande	—	—	`2026-03-09T02:34:37`
`customer_id`	texte	oui	Client	« C » + 8 chiffres	Identifiant indirect	`C00052834`
`channel`	texte	oui	Canal de vente	web, mobile, marketplace	—	`marketplace`
`payment_method`	texte	oui	Moyen de paiement	card, wallet, transfer, gift_card	—	`card`
`status`	texte	oui	Statut de la commande	paid, shipped, delivered, cancelled	—	`paid`
`promo_code`	texte	oui	Code promo (NONE si aucun)	NONE, LOYAL5, WELCOME10, FLASH15, SUMMER20	—	`NONE`

3. Lignes de commandes en ligne — `order_items`

Une ligne par produit d'une commande en ligne. Livrée avec les commandes du même jour métier.

Propriété	Valeur
Fichier source	`raw/orders/order_items.csv.gz` (CSV compressé)
Volume	1 000 000 lignes
Mode d'ingestion	batch, livraison quotidienne
Clé primaire	`order_item_id`
Date métier	`order_ts`
Propriétaire	Équipe E-commerce

Colonne	Type	Obligatoire	Description	Règles / valeurs autorisées	RGPD	Exemple
`order_item_id`	entier	oui	Identifiant de ligne	≥ 1	—	`1`
`order_id`	texte	oui	Commande parente	« O » + 10 chiffres	—	`O0000311489`
`product_id`	texte	oui	Produit	« P » + 7 chiffres	—	`P0005236`
`qty`	entier	oui	Quantité	≥ 1	—	`4`
`unit_price`	décimal	oui	Prix unitaire	≥ 0 ; unité : EUR	—	`29.36`
`discount_rate`	décimal	oui	Taux de remise	≥ 0 ; ≤ 1	—	`0.00`
`net_amount`	décimal	oui	Montant net de la ligne	≥ 0 ; unité : EUR	—	`117.44`

4. Retours — `returns`

Une ligne par retour de produit enregistré par l'entrepôt.

Propriété	Valeur
Fichier source	`raw/returns/returns.csv.gz` (CSV compressé)
Volume	100 000 lignes
Mode d'ingestion	batch, livraison quotidienne
Clé primaire	`return_id`
Date métier	`return_ts`
Propriétaire	Équipe Logistique

Colonne	Type	Obligatoire	Description	Règles / valeurs autorisées	RGPD	Exemple
`return_id`	texte	oui	Identifiant du retour	« R » + 9 chiffres	—	`R000000001`
`return_ts`	horodatage	oui	Horodatage de réception du retour	—	—	`2025-10-12T01:23:37`
`order_id`	texte	oui	Commande d'origine	« O » + 10 chiffres	—	`O0000414893`
`product_id`	texte	oui	Produit retourné	« P » + 7 chiffres	—	`P0008136`
`return_qty`	entier	oui	Quantité retournée	≥ 1	—	`2`
`reason`	texte	oui	Motif	late, wrong_item, damaged, size_issue, not_as_expected, other	—	`late`

Colonne	Type	Obligatoire	Description	Règles / valeurs autorisées	RGPD	Exemple
`return_amount`	décimal	oui	Montant remboursé	≥ 0 ; unité : EUR	—	`94.29`

5. Référentiel clients — `customers`

Photo complète du référentiel clients. Les changements ultérieurs arrivent par le flux CDC customer_updates.

Propriété	Valeur
Fichier source	`raw/customers/customers.csv.gz` (CSV compressé)
Volume	100 000 lignes
Mode d'ingestion	batch, livraison photo complète ponctuelle
Clé primaire	`customer_id`
Date métier	aucune (photo au 2025-01-01)
Propriétaire	Équipe CRM (relation client)

Colonne	Type	Obligatoire	Description	Règles / valeurs autorisées	RGPD	Exemple
`customer_id`	texte	oui	Identifiant client	« C » + 8 chiffres	Identifiant indirect	`C00000001`
`customer_key`	entier	oui	Clé technique source	—	—	`1`
`region`	texte	non	Région (quelques NULL connus)	IDF, Nord, Est, Ouest, Sud-Est, Sud-Ouest, Centre, International	—	`IDF`
`segment`	texte	oui	Segment client	Standard, Premium, Etudiant, Entreprise	—	`Standard`
`signup_date`	date	oui	Date d'inscription	—	—	`2025-01-01`
`consent_marketing`	booléen	oui	Consentement marketing (base légale RGPD)	—	—	`false`
`email_pseudo`	texte	oui	E-mail pseudonymisé à la source — non propagé après Bronze	—	Donnée personnelle	(masqué)
`phone_pseudo`	texte	oui	Téléphone pseudonymisé à la source — non propagé après Bronze	—	Donnée personnelle	(masqué)
`is_active`	booléen	oui	Client actif	—	—	`false`

6. Changements clients (CDC) — `customer_updates`

Changements du référentiel clients (U = mise à jour, D = suppression). Source de l'historisation SCD2.

Propriété	Valeur
Fichier source	`cdc/customer_updates.jsonl.gz` (JSONL compressé)
Volume	50 000 lignes
Mode d'ingestion	batch, livraison à chaque lot de changements
Clé primaire	aucune (plusieurs événements possibles par client)
Date métier	`change_ts`
Propriétaire	Équipe CRM (relation client)

Colonne	Type	Obligatoire	Description	Règles / valeurs autorisées	RGPD	Exemple
`op`	texte	oui	Type d'opération	U, D	—	`U`
`customer_id`	texte	oui	Client concerné	« C » + 8 chiffres	Identifiant indirect	`C00097314`
`change_ts`	horodatage	oui	Horodatage du changement	—	—	`2026-08-01T12:00:00`
`new_region`	texte	non	Nouvelle région	IDF, Nord, Est, Ouest, Sud-Est, Sud-Ouest, Centre, International	—	`International`
`new_segment`	texte	non	Nouveau segment	Standard, Premium, Etudiant, Entreprise	—	`Entreprise`
`new_consent_marketing`	booléen	non	Nouveau consentement	—	—	`true`

7. Catalogue produits — `products`

Photo complète du catalogue produits.

Propriété	Valeur
Fichier source	`raw/products/products.csv.gz` (CSV compressé)
Volume	20 000 lignes
Mode d'ingestion	batch, livraison photo complète ponctuelle
Clé primaire	`product_id`
Date métier	aucune (photo au 2025-01-01)
Propriétaire	Équipe Offre produits

Colonne	Type	Obligatoire	Description	Règles / valeurs autorisées	RGPD	Exemple
`product_id`	texte	oui	Identifiant produit	« P » + 7 chiffres	—	`P0000001`
`product_key`	entier	oui	Clé technique source	—	—	`1`
`sku`	texte	oui	Référence article	« SKU- » + 8 chiffres	—	`SKU-00000001`

Colonne	Type	Obligatoire	Description	Règles / valeurs autorisées	RGPD	Exemple
`category`	texte	oui	Catégorie	Beauty, Electronics, Sports, Fashion, Grocery, Home	—	`Beauty`
`subcategory`	texte	oui	Sous-catégorie	A, B, C, D	—	`A`
`brand`	texte	oui	Marque	—	—	`Brand_391`
`unit_cost`	décimal	oui	Coût d'achat unitaire	≥ 0 ; unité : EUR	—	`48.99`
`list_price`	décimal	oui	Prix catalogue	≥ 0 ; unité : EUR	—	`87.37`
`vat_rate`	décimal	oui	Taux de TVA	0.055, 0.1, 0.2	—	`0.2`
`is_active`	booléen	oui	Produit actif	—	—	`true`
`effective_from`	date	oui	Début de validité	—	—	`2025-01-01`
`effective_to`	date	non	Fin de validité (NULL = version courante)	—	—	*vide*
`is_current`	booléen	oui	Version courante	—	—	`true`

8. Référentiel magasins — `stores`

Photo complète des magasins NeoRetail.

Propriété	Valeur
Fichier source	`raw/stores/stores.csv.gz` (CSV compressé)
Volume	200 lignes
Mode d'ingestion	batch, livraison photo complète ponctuelle
Clé primaire	`store_id`
Date métier	aucune (photo au 2025-01-01)
Propriétaire	Équipe Magasins

Colonne	Type	Obligatoire	Description	Règles / valeurs autorisées	RGPD	Exemple
`store_id`	texte	oui	Identifiant magasin	« S » + 4 chiffres	—	`S0001`
`store_key`	entier	oui	Clé technique source	—	—	`1`
`city`	texte	oui	Ville	—	—	`Bordeaux`
`format`	texte	oui	Format de magasin	proximity, super, hyper, outlet	—	`super`
`is_active`	booléen	oui	Magasin ouvert	—	—	`true`

9. Navigation web (clickstream) — `clickstream`

Un événement de navigation web / mobile. Publié dans le topic clickstream.events.v1.

Propriété	Valeur
Fichier source	`stream/clickstream.jsonl.gz` (JSONL compressé)
Volume	1 000 000 lignes
Mode d'ingestion	temps réel (Redpanda)
Clé primaire	`event_id`
Date métier	`event_ts`
Propriétaire	Équipe Digital

Colonne	Type	Obligatoire	Description	Règles / valeurs autorisées	RGPD	Exemple
`event_id`	texte	oui	Identifiant d'événement	« E » + 12 chiffres	—	`E000000000001`
`event_ts`	horodatage	oui	Horodatage de l'événement	—	—	`2025-05-30T00:34:05`
`session_id`	texte	oui	Session de navigation	—	—	`SESS0000373963`
`customer_id`	texte	oui	Client	« C » + 8 chiffres	Identifiant indirect	`C00096372`
`event_type`	texte	oui	Type d'événement	page_view, product_view, search, add_to_cart, checkout, purchase	—	`search`
`product_id`	texte	non	Produit (NULL pour les pages sans produit)	« P » + 7 chiffres	—	*vide*
`device`	texte	oui	Appareil	desktop, mobile, tablet	—	`desktop`
`source`	texte	oui	Source de trafic	direct, seo, ads, social, email	—	`direct`
`latency_ms`	entier	oui	Latence de chargement (ms)	≥ 0	—	`115`

Source hors périmètre de la première version

`raw/erp/gl_entries.csv.gz` (100 000 écritures comptables : `entry_id`, `posting_date`, `account_code`, `cost_center`, `document_type`, `amount`, `currency`). Toutes les écritures sont datées du 01/01/2025 (voir profilage, anomalie A8) : aucune analyse financière dans le temps n'est possible. Source non ingérée pour l'instant.